Guía de trabajo: dos secuencias paired-end en Google Colab

Muestras compartidas para todo el grupo · Descarga desde NCBI SRA y preparación para TORMES

Las dos secuencias que usará todo el grupo

SRR40223459 y **SRR12056271**. Son los dos accession que se descargaron al inicio y que se organizaron en el servidor como dos muestras paired-end. Cada muestra debe producir un archivo R1 (_1) y un archivo R2 (_2). Antes de iniciar el análisis, comprueba que ambos archivos existan.

1. Abrir Google Colab

Entra a Google Colab, crea un cuaderno nuevo y ejecuta cada bloque en una celda independiente. Si Colab se reinicia, vuelve a ejecutar las celdas necesarias.

2. Comprobar espacio y memoria

```
!df -h /\n!nproc\n!free -h
```

3. Instalar herramientas para descargar SRA

```
%%bash
set -e
apt-get update -qq
apt-get install -y sra-toolkit gzip
```

4. Descargar y convertir las dos muestras

Copia el bloque completo en una celda nueva. Descarga los dos runs, los convierte en archivos paired-end y comprime los FASTQ. La descarga y conversión pueden tardar.

```
%%bash
set -euo pipefail

WORK="/content/fastq"
SRA_DIR="/content/sra"
mkdir -p "$WORK" "$SRA_DIR"

for SRR in SRR40223459 SRR12056271; do
  echo "=== Descargando $SRR ==="
  mkdir -p "$WORK/Carpeta_1/$SRR"

  prefetch "$SRR" --output-directory "$SRA_DIR"

  fasterq-dump "$SRA_DIR/$SRR/$SRR.sra" \
    --split-files --threads 2 \
    --outdir "$WORK/Carpeta_1/$SRR"

  gzip "$WORK/Carpeta_1/$SRR/${SRR}_1.fastq" \
       "$WORK/Carpeta_1/$SRR/${SRR}_2.fastq"

  gzip -t "$WORK/Carpeta_1/$SRR/${SRR}_1.fastq.gz" \
          "$WORK/Carpeta_1/$SRR/${SRR}_2.fastq.gz"

  echo "=== Archivos listos para $SRR ==="
  ls -lh "$WORK/Carpeta_1/$SRR"
done
```

5. Verificar los cuatro FASTQ

```
!find /content/fastq -type f -name '*.fastq.gz' -printf '%p  %s bytes\\n' | sort
```

El resultado debe mostrar cuatro archivos: SRR40223459_1.fastq.gz, SRR40223459_2.fastq.gz, SRR12056271_1.fastq.gz y SRR12056271_2.fastq.gz, cada uno dentro de la carpeta de su muestra.

```
%%bash
set -euo pipefail
```

```
for f in /content/fastq/Carpeta_1/*/*.fastq.gz; do
  echo "Verificando: $f"
  gzip -t "$f"
done
echo "Verificación gzip completada sin errores."
```

Estructura esperada

```
/content/fastq/Carpeta_1/
■■■ SRR40223459/
■    ■■■ SRR40223459_1.fastq.gz
■    ■■■ SRR40223459_2.fastq.gz
■■■ SRR12056271/
    ■■■ SRR12056271_1.fastq.gz
    ■■■ SRR12056271_2.fastq.gz
```

Importante: estos archivos viven en el almacenamiento temporal de Colab. Si la sesión se reinicia o desconecta, puede que tengas que descargarlos otra vez. Para conservarlos, súbelos a Google Drive o guarda allí los resultados.

6. Obtener el repositorio oficial de TORMES

```
!git clone https://github.com/nmquijada/tormes.git
%cd /content/tormes
!git tag --list
!ls -la
```

Repositorio oficial: github.com/nmquijada/tormes. Revisa el README y los archivos incluidos para localizar las instrucciones y el archivo de entorno de la versión que se va a instalar. No uses un nombre de YAML supuesto ni una URL de terceros sin verificar.

7. Crear el entorno Conda

Una vez que identifiques el nombre exacto del archivo de entorno oficial incluido en el repositorio, usa este patrón y reemplaza ARCHIVO_DE_ENTORNO.yml por el nombre real:

```
!mamba env create -n tormes-1.3.0 -f ARCHIVO_DE_ENTORNO.yml
```

> El texto ARCHIVO_DE_ENTORNO.yml es un marcador: no lo ejecutes literalmente. La versión 1.3.0 es antigua y puede presentar incompatibilidades con el entorno actual de Colab.

8. Verificar la instalación

```
!conda env list\n!conda run -n tormes-1.3.0 tormes --help
```

Si el comando de ayuda funciona, sigue la sintaxis de metadatos y análisis documentada para esa versión. El formato de metadatos debe relacionar cada muestra con sus FASTQ Forward y Reverse. No ejecutes el análisis con nombres de columnas u opciones inventadas.

9. Guardar resultados en Google Drive

```
from google.colab import drive\ndrive.mount('/content/drive')
```

Guarda los resultados finales en una carpeta de Drive antes de que la sesión termine.

Enlaces útiles

NCBI SRA: ncbi.nlm.nih.gov/sra
SRA Toolkit: github.com/ncbi/sra-tools
TORMES: github.com/nmquijada/tormes

Metadata de TORMES para Google Colab

Dos muestras paired-end compartidas para todo el grupo

1. Antes de generar el metadata

Este ejemplo usa las rutas que quedaron en la guía de descarga: /content/fastq/Carpeta_1/SRR40223459/ y /content/fastq/Carpeta_1/SRR12056271/. Deben existir los cuatro FASTQ comprimidos antes de ejecutar el bloque.

2. Copiar y pegar en una celda de Colab

```
from pathlib import Path
import csv

base = Path("/content/fastq/Carpeta_1")

rows = [
    [
        "SRR40223459",
        str((base / "SRR40223459" / "SRR40223459_1.fastq.gz").resolve()),
        str((base / "SRR40223459" / "SRR40223459_2.fastq.gz").resolve()),
        "Lecturas Illumina paired-end descargadas de NCBI SRA"
    ],
    [
        "SRR12056271",
        str((base / "SRR12056271" / "SRR12056271_1.fastq.gz").resolve()),
        str((base / "SRR12056271" / "SRR12056271_2.fastq.gz").resolve()),
        "Lecturas Illumina paired-end descargadas de NCBI SRA"
    ],
]

metadata = Path("/content/tormes-metadata.txt")
with metadata.open("w", newline="") as f:
    writer = csv.writer(f, delimiter="\\t", lineterminator="\\n")
    writer.writerow(["Samples", "Read1", "Read2", "Description"])
    writer.writerows(rows)

print(metadata.read_text())
print("Metadata guardado en:", metadata)
```

El archivo se guarda como /content/tormes-metadata.txt. La primera columna debe llamarse Samples; la segunda Read1 y la tercera Read2. Las columnas deben estar separadas por tabuladores, no por espacios. Description es opcional, pero se incluye para documentar las muestras.

3. Comprobar que las rutas existen

```
from pathlib import Path

for sample in ["SRR40223459", "SRR12056271"]:
    folder = Path("/content/fastq/Carpeta_1") / sample
    for suffix in ["_1.fastq.gz", "_2.fastq.gz"]:
        p = folder / f"{sample}{suffix}"
        print("OK" if p.is_file() else "FALTA", p)
```

> Continúa solo si aparecen los cuatro archivos como OK. Si aparece FALTA, revisa la descarga y las rutas antes de correr TORMES.

4. Ejecutar TORMES

Cuando TORMES 1.3.0 esté instalado y tormes-setup haya terminado, ejecuta:

```
!conda run -n tormes-1.3.0 tormes \
  --metadata /content/tormes-metadata.txt \
  --output /content/tormes-output \
  --threads 2
```

> La opción --threads debe confirmarse en la ayuda de la versión instalada; si esa versión no la reconoce, consulta !conda run -n tormes-1.3.0 tormes --help y elimina esa opción. El análisis puede tardar bastante y las bases de datos de TORMES requieren espacio.

5. Guardar los resultados en Google Drive

```
from google.colab import drive
drive.mount("/content/drive")

# Copia la carpeta de resultados a tu Drive
!cp -r /content/tormes-output /content/drive/MyDrive/tormes-output
```

Formato oficial del metadata: TORMES requiere columnas tabuladas Samples, Read1 y Read2; las columnas descriptivas posteriores son opcionales. Documentación: repositorio oficial de TORMES.