




Introducción al análisis de mutaciones puntuales en datos NGS

Luis Enrique Romero Cruz

Octubre 2025



El inicio de la era genómica



- 1990 Inicia el Proyecto Genoma Humano
- 2003 Se terminó de secuenciar las 2000 millones de pares de bases que componen el genoma humano


El genoma humano

- Conjunto de todo el material genético (genes) característico de un organismo
- Secuencia de DNA consenso representativa de una especie.

Curiosidades del genoma humano

- Se estima que contiene 18,000 – 25,000 genes
- Solo el 1.5% del genoma es codificante

Genome size (A species comparison)



Variabilidad genética humana

Se estima que existe un 1% de variabilidad genómica entre los seres humanos


La forma más común de variabilidad son los polimorfismos de un solo nucleótido (SNP's)



Referencia genómica




Variabilidad < 1 %



Variabilidad > 1 %

Referencia Genómica


chr1




SNV


delección

inserción



Flujo de trabajo






Muestra




Extracción de
DNA



Preparación
de bibliotecas



Secuenciadores
NGS




Secuencias en
"bruto"




Alineamiento

```
AGTCCCTGAATCGATGCTACATGCAAG  
AACTGATCCTAGATCGACGATCACGTG  
AAACCCTTAGATGACGGTCAGCCGCAA  
GCGGAATTGCGACATAACAAGTACTG  
AGTCGGCGTTCGCCTAACCGCAGTATT  
TTCCAGGCCCTTCTGCCGAGCTGATGC  
AGCCACAATCGGGCTGAGGGGTCTTGG  
AAACGGGTGGGGTAACGCCGTGATCGC
```



Secuencia en bruto: Formato FASTQ

- Nombre de la secuencia
- Secuencia de Nucleotidos
- + (opcional: nombre de la secuencia de nuevo)
- Puntaje de calidad asociado
- Terminación .fastq .fq
fastq.gz fq.gz



$$\text{Phread value} = -10 * \log_{10}(E)$$

90% de confiabilidad (10% rango de error) = Q10

99% de confiabilidad (1% rango de error) = Q20

99.9% de confiabilidad (0.1% rango de error) = Q30

Alineamiento BWA -mem

```
bwa mem \  
-t 18 \  
-M \  
-R $(echo "@RG\tID:$prefix_id\tSM:$prefix_id\tLB:Sophia\tPL:ILLUMINA") \  
Genomic_ref.fasta \  
read1.fastq read2.fastq > output.sam
```

Explicación de los argumentos y parámetros usados para bwa

mem: Algoritmo (Maximal exact matches) especializado para secuencias pair-end de mas de 70bp

-t: Numero de núcleos a usar

-M: Marcar los alineamientos cortos como secundarios (compatibilidad con Picard)

-R: Etiqueta “readgroups” Que es un identificador de la muestra (ID-paciente, SM-muestra, LB-Librería, PL-plataforma)

Genomic_reference: Referencia genómica de nuestro organismo en formato fasta (hg38)

Read1: Secuencia forward en formato fastq

Read2: Sencuencia reverse en formato fastq

Output: Nombre de nuestro archivo de salida (se recomienda que sea en formato .sam)

Ordemiento de archivo sam

```
samtools sort file.sam -o output.sorted.sam
```

Conversión de .sam a .bam


```
samtools view -b file.sorted.sam -o output.sorted.bam
```

Indexado del archivo .bam

```
samtools index -b file.sorted.bam
```

Esto genera un archivo con exactamente el mismo nombre que file.sorted.bam como file.sorted.bam.bai

Secuencia alineada: Formato SAM/BAM





```
@HD      VN:1.0  S0:coordinate
@SQ      SN:chr20      LN:64444167
@PG      ID:TopHat      VN:2.0.14      CL:/srv/dna_tools/tophat/tophat -N 3 --read-edit-dist 5 --read-realign-edit-dist 2 -i 50 -I 5000 --max-coverage-intron 5000 -M -o out /data/user446/mapping_tophat/index/chr20 /data/user446/mapping_tophat/L6_18_GTGAAA_L007_R1_001.fastq
HWI-ST1145:74:C101DACXX:7:1102:4284:73714      16      chr20      190930      3      100M      *      0      0
      CCGTGTTTAAAGGTGGATGCGGTCACCTTCCCAGCTAGGCTTAGGGATTCTTAGTTGGCCTAGGAAATCCAGCTAGTCCTGTCTCTCAGTCCCCCTCT
C      BBDCDDCCDDDDDCDDDDDDDCDDCCDBC?DDDDDDDDDDDDDDDDCCDDDDDDDDDDDDDDDDDDDDDDDBDHFFFFDC@@
      AS:i:-15      XM:i:3      XO:i:0      XG:i:0      MD:Z:55C20C13A9      NM:i:3      NH:i:2      CC:Z:=      CP:i:55352714      HI:i:0
HWI-ST1145:74:C101DACXX:7:1114:2759:41961      16      chr20      193953      50      100M      *      0      0
      TGCTGGATCATCTGGTTAGTGGCTTCTGACTCAGAGGACCTTCGTCCCCTGGGGCAGTGGACCTTCCAGTGATTCCCCTGACATAAGGGGCATGGACGA
G      DCDDDDDEDDDDDDDCDDDDDDDCDDDDDEEC>DFFFEJJJJJIGJJJJIIHGBHHGJIJJJJJJGJJJIJJJJIIHJJJJJJHHHHHFFFFFCCC
      AS:i:-16      XM:i:3      XO:i:0      XG:i:0      MD:Z:60G16T18T3      NM:i:3      NH:i:1
HWI-ST1145:74:C101DACXX:7:1204:14760:4030      16      chr20      270877      50      100M      *      0      0
      GGCTTTATTGGTAAAAAAGGAATAGCAGATTTAATCAGAAATTTCCACCTGGCCCAGCAGCACCAACCAGAAAGAAGGAAGAAGACAGGAAAAAACCA
C      DDDDDDDDDCCDDDDDDDDDDDEEEEEEEFFFEFFEGHHHHFGDJJIHJJJIJJJJIIIIIGGFJJIIIIIIJJJJJJIGHHFAHGFHJHFGGHFFFDDBB
      AS:i:-11      XM:i:2      XO:i:0      XG:i:0      MD:Z:0A85G13      NM:i:2      NH:i:1
HWI-ST1145:74:C101DACXX:7:1210:11167:8699      0      chr20      271218      50      50M4700N50M      *      0
      0      GTGGCTCTTCCACAGGAATGTTGAGGATGACATCCATGTCTGGGGTGCACCTTGGGTCTCCGAAGCAGAACATCCTCAAATATGACCTCTCG
accepted_hits.sam
```




Ingresando al Docker de GATK

```
docker run --rm -v /my/files:/docker_dict -it broadinstitute/gatk bash
```



Re-calibramiento de bases

Example of bias: qualities reported depending on nucleotide context



Cada equipo de secuenciación es diferente y la asignación de calidad a las bases puede estar sesgada por errores sistemáticos del equipo.

Recalibramiento de bases GATK

```
gatk BaseRecalibrator \  
-I file.bam \  
--known-sites Docker_dict/Homo_sapiens_assembly38.dbsnp138.vcf \  
-O output_file.table \  
-R Docker_ditc/hg38.fa
```

Explicación de los argumentos y parámetros usados para GATK BaseRecalibrator

- I Input:** archivo de entrada.bam (debe existir su respectivo archivo.bam.bai en el mismo directorio)
- known-sites:** variantes genómicas comunes que servirán para calibrar los valores de calidad que emitió el secuenciador
- O Output:** archivo que tiene los valores recalibrados de las variantes “known-sites vs nuestras secuencias”
- R** Referencia genómica en formato fasta

Aplicando el recalibramiento

```
gatk ApplyBQSR \  
  -R Docker_dict/hg38.fa \  
  -I file.bam \  
  --bqsr-recal-file file.table \  
  -O output.recal.bam  
  
samtools index -b output.recal.bam
```

Llamado de variantes

```
gatk HaplotypeCaller \  
-R Docker_dict/hg38.fa \  
-I file.recal.bam \  
-O output.vcf \
```

VCF header

```
##fileformat=VCFv4.0  
##fileDate=20100707  
##source=VCFtools  
##reference=NCBI36  
##INFO=<ID=AA,Number=1,Type=String,Description="Ancestral Allele">  
##INFO=<ID=H2,Number=0,Type=Flag,Description="HapMap2 membership">  
##FORMAT=<ID=GT,Number=1,Type=String,Description="Genotype">  
##FORMAT=<ID=GQ,Number=1,Type=Integer,Description="Genotype Quality (phred score)">  
##FORMAT=<ID=GL,Number=3,Type=Float,Description="Likelihoods for RR,RA,AA genotypes (R=ref,A=alt)">  
##FORMAT=<ID=DP,Number=1,Type=Integer,Description="Read Depth">  
##ALT=<ID=DEL,Description="Deletion">  
##INFO=<ID=SVTYPE,Number=1,Type=String,Description="Type of structural variant">  
##INFO=<ID=END,Number=1,Type=Integer,Description="End position of the variant">
```

Mandatory header lines

Optional header lines (meta-data about the annotations in the VCF body)

Body

#CHROM	POS	ID	REF	ALT	QUAL	FILTER	INFO	FORMAT	SAMPLE1	SAMPLE2
1	1	.	ACG	A,AT	.	PASS	.	GT:DP	1/2:13	0/0:29
1	2	rs1	C	T,CT	.	PASS	H2;AA=T	GT:GQ	0 1:100	2/2:70
1	5	.	A	G	.	PASS	.	GT:GQ	1 0:77	1/1:95
1	100	.	T		.	PASS	SVTYPE=DEL;END=300	GT:GQ:DP	1/1:12:3	0/0:20

Reference alleles (GT=0)

Alternate alleles (GT>0 is an index to the ALT column)

Deletion

SNP

Large SV

Insertion

Other event

Phased data (G and C above are on the same chromosome)

Wannovar y bases genómicas



Anotación de variantes genómicas

Wannovar facilita la anotación y el análisis de variantes genómicas, permitiendo una interpretación clínica más precisa.

Integración de bases de datos

La herramienta permite combinar múltiples bases de datos, mejorando la interpretación funcional de las variantes encontradas.

Optimización en medicina personalizada

Wannovar agiliza la identificación de mutaciones relevantes, apoyando el avance de la medicina personalizada y las investigaciones genéticas.

<https://wannovar.wglab.org>

ANNOVAR is a rapid, efficient tool to annotate functional consequences of genetic variation from high-throughput sequencing data. wANNOVAR provides easy and intuitive web-based access to the most popular functionalities of the ANNOVAR software

Contact

By default, wANNOVAR performs "individual analysis" on the first sample in your VCF file to help find disease genes (you may need to split your multi-sample VCF file to individual files for annotation separately to find disease genes). If you only want to annotate all variant sites in a multi-sample VCF file, select "All Annotations" option below (for example, if your VCF contains variant calls for a pair of normal and tumor sample, or if your VCF contains

[7/12/2024] The wANNOVAR server is updated to 2024 version with dbNSFP v4.7a and gnomAD v4.1 (hg38) or gnomAD v2.1.1 (hg19).



Submission 484252

Your submission has been received by the ANNOVAR server at Mon Oct 13 01:53:53 2025.

The results will be generated at </done/484252/OS4nYGD0RRXbL6iJ/index.html> after the computation is done.

WARNING WARNING WARNING: Many email servers nowadays block suspicious emails with URL inside, so you may NOT receive an email, and all results will be deleted every 24 hours. Therefore, it is best that you record the URL for results (such as bookmarking it), or keep the browser open until results are shown.

A summary of input file

User input contains 955 lines



ClinVar: Base de datos genética

Recopilación de variantes genéticas

ClinVar recopila información sobre variantes genéticas y sus vínculos con enfermedades humanas, facilitando la investigación y la medicina.

Intercambio de información científica y médica

La base de datos posibilita el intercambio de datos entre científicos y médicos para mejorar la comprensión genética.

Interpretación clínica y tratamiento personalizado

ClinVar ayuda en la interpretación clínica de mutaciones, apoyando diagnósticos precisos y tratamientos personalizados para los pacientes.

Actividad

- Realiza el análisis bioinformático para los tres pacientes:
- Paciente1
- Paciente2
- Paciente3
- Opcional:
- Crea un script en bash para que realice todo el flujo de trabajo bioinformático para cualquier numero de muestras

“HAGAN EQUIPOS DE 2”

DESCONOCIDX CIENTÍFICX

